



Алгоритмы программирования и структуры данных

Хеширование




Хеш-функции




Хорошая хеш-функция

- ▶ Все m хеш-значений равновероятны
 - ▶ Можно считать, что ключи из множества U выбираются независимо
- ▶ $\sum_{x:h(x)=j} P(x) = \frac{1}{m}$, для $j = 0, 1, \dots, m - 1$
- ▶ Если выбрать все маленькие объекты, например, строки маленькой длины, то коллизии на всех таких объектах не случится
- ▶ Хеш-функция не имеет никакой зависимости с построением объектов
- ▶ Значение хеш-функции — целое число




Переход к целым неотрицательным числам

- ▶ Любой объект можно записать, как целое число
 - ▶ Это число может быть большим
- ▶ Например, строка это длинное число в системе счисления размер алфавита
- ▶ Более формально, можно сделать функцию $k(x)$, которая инъективно отображает U в множество целых неотрицательных чисел




Метод деления с остатком

- ▶ Выбирается число p
- ▶ Хеш-функция: $h(x) = k(x) \bmod p$
- ▶ В качестве p хорошо выбирать простое число, никак не зависящее от функции $k(x)$ и множества U
- ▶ Следует избегать $p = 2^k$, потому что это просто последние k бит числа
 - ▶ На практике такое p дает рост производительности
 - ▶ Числа в машине в двоичной записи
 - ▶ Если потеря старших битов не помешают хорошему хешированию, можно воспользоваться



Метод умножения

- ▶ Выберем константу A в интервале $0 < A < 1$
- ▶ $h(x) = \lfloor m((k(x) \cdot A) \bmod 1) \rfloor$
 - ▶ $z \bmod 1$ — дробная часть числа z
- ▶ Качество хеширования мало зависит от выбора m
- ▶ Обычно выбирают m , как какую-то степень двойки
 - ▶ Сдвиг машинного слова



Хеширование строк

► Полиномиальное хеширование

► $k(s) = \sum_{i=1}^{|s|} s_i t^{|s|-i}$

► Число t надо выбирать больше размера алфавита

► Пусть $t = 23$, и у нас латинский алфавит с номерами букв от 1 до 26

► Тогда строки `ba` и `ax` имеют одинаковый хеш

► $h(ba) = 2 \cdot 23 + 1 = 47$

► $h(ax) = 1 \cdot 23 + 24 = 47$

► $h(s) = \sum_{i=1}^{|s|} s_i t^{|s|-i} \bmod p$

► Легкость пересчета хеш-функции при дописывании и изменении буквы или подстроки

► Выбрать случайные g_i

► $h(s) = \sum_{i=1}^{|s|} s_i g_i \bmod p$

► Числа g_i должны быть больше размера алфавита